

离网型绿电制氢合成氨系统优化调度策略研究

王东风, 师鑫鑫, 崔玉雷, 梁博彦, 黄宇

华北电力大学 自动化系, 河北 保定 071003

基金项目: 国家自然科学基金资助项目 (52207235)

摘要: 针对离网型绿电制氢合成氨系统因可再生能源出力波动导致的合成氨装置运行不稳定问题, 提出一种基于风光功率预测与场景分析的随机模型预测控制调度策略。构建了绿电制氢合成氨系统的状态空间模型, 确立以风光消纳率与合成氨产量最大化为目标的优化函数, 并设定系统运行约束条件。利用 Transformer-KAN 混合预测模型对风光出力进行预测, 通过拉丁超立方抽样与 K-means 聚类技术生成典型场景集, 以量化出力不确定性。采用随机模型预测控制策略对系统进行调度优化, 通过滚动时域优化结合实时反馈校正机制, 动态适配风光波动。以某日风光出力为例进行算例验证, 结果表明用所提模型及调度策略可有效提升风光能源消纳率, 其消纳率由传统模型预测控制策略的 98.23% 提高到 99.86%, 同时保障合成氨系统稳定高效运行, 合成氨产量由传统模型预测控制策略的 4.96 MW 提高到 4.99 MW。

关键词: 离网型; 风光功率预测; 电氢氨系统; 优化调度; 场景分析; Transformer-KAN

中图分类号: TM732 文献标识码: A 文章编号: 1672-0792(2025)11-0011-10

DOI: 10.3969/j.issn.1672-0792.2025.11.002

Research on Optimal Scheduling Strategies for Off-grid Green Power-hydrogen-to-ammonia Systems

WANG Dongfeng, SHI Xinxin, CUI Yulei, LIANG Boyan, HUANG Yu

Department of Automation, North China Electric Power University, Baoding 071003, China

Abstract: To address the operational instability of off-grid green power-to-hydrogen-to-ammonia system caused by fluctuations in renewable energy output in off-grid green power-to-hydrogen production, this paper proposes a stochastic model predictive control scheduling strategy based on wind and solar power forecasting and scenario analysis. A state-space model of the green power-to-hydrogen-to-ammonia system is constructed, establishing an optimization function aimed at maximizing the utilization rate of wind and solar energy and ammonia yield, while setting operational constraints. A transformer-KAN hybrid forecasting model is utilized to predict wind and solar output, and typical scenario sets are generated using Latin hypercube sampling and K-means clustering techniques to quantify output uncertainty. The stochastic model predictive control strategy is employed for optimization scheduling of the system, dynamically adapting to wind and solar fluctuations through rolling horizon optimization combined with a real-time feedback correction mechanism. A case study using a day's wind and solar output is performed for validation. Results show that the proposed model and scheduling strategy significantly improve the utilization rate of renewable energy, increasing from 98.23% with traditional MPC strategies to 99.86%; while ensuring stable and efficient operation of the ammonia synthesis system, with ammonia production increasing from 4.96 MW to 4.99 MW compared to traditional MPC strategies.

引用格式: 王东风, 师鑫鑫, 崔玉雷, 等. 离网型绿电制氢合成氨系统优化调度策略研究[J]. 电力科学与工程, 2025, 41(11): 11-20. WANG Dongfeng, SHI Xinxin, CUI Yulei, et al. Research on optimal scheduling strategies for off-grid green power-hydrogen-to-ammonia systems[J]. Electric Power Science and Engineering, 2025, 41(11): 11-20.

Key words: off-grid; wind and solar power forecasting; green power-to-hydrogen-to-ammonia system; optimal scheduling; scenario analysis; transformer-KAN

0 引言

在全球能源转型背景下,氢能作为清洁高效的二次能源,其重要性日益凸显^[1]。其中,利用可再生能源电解水生产绿氢,因其零碳排放特性被广泛认为是未来低碳能源体系的关键能源^[2]。合成氨作为农业与工业领域的核心化工产品,其传统生产工艺高度依赖化石能源制氢,存在能耗高、碳排放量大的缺陷。因此,推动绿氢产业与合成氨产业的深度协同^[3,4],不仅为传统高碳合成氨工艺提供了低碳化替代路径,并能构建“绿电-绿氢-绿氨”的零碳一体化系统^[5]。这种协同不仅有助于推动传统高碳流程的深度脱碳,也为实现清洁能源的高效利用提供了新路径^[6]。然而,绿电制氢合成氨系统在离网型运行条件下,风光能源出力的间歇性与波动性会导致合成氨装置运行不稳定^[7]。一方面,供能波动易引发合成氨系统频繁启停,影响工艺稳定性与设备寿命。另一方面,绿电资源难以被充分利用,造成弃电现象,制约了系统整体能效^[8]。因此,如何通过先进控制策略实现可再生能源波动与合成氨工艺负荷需求的动态匹配,成为绿电制氢合成氨系统工程化应用的关键^[8]。

目前,关于绿电制氢合成氨系统的调控研究仍处于初步探索阶段。文献[9]从经济性角度出发,评估了绿氢制氨系统的可行性,验证了以氨为能源载体实现能量储存与调节的潜力,但未深入研究系统及调控策略问题。文献[10]引入多稳态柔性工艺的概念,提出了面向绿氨系统的多稳态柔性调度方法,为系统适应可再生能源波动提供了安全且经济可行的调度优化途径。文献[11]构建了面向绿电-氢-氨耦合系统的自适应分布式鲁棒调度优化模型,以提高系统在不确定条件下的稳定性与抗扰性,有效缓解了传统鲁棒方法在实际应用中的保守性问题。文献[12]提出了一种混合多频柔性绿氨系统的容量设计与调度优化方法,通过宽域负荷调控与分钟级响应,解决多频幅波动下电氢氨匹配难题,为并网/离网场景提供了安全经济

的优化方案。上述研究,尽管在可再生能源制氢合成氨系统的不同维度取得了进展,但均未考虑闭环控制的实现机制。

模型预测控制 (Model predictive control, MPC) 具有闭环控制特性^[13],能够根据系统的实时反馈信息动态调整控制策略,从而有效提升系统的鲁棒性、响应速度及运行稳定性,使其在多变环境下仍可保持最佳性能^[14]。文献[15]针对集中式优化多微网系统面临的高计算负荷及源-荷不确定性引发的运行稳定性挑战,提出了基于MPC的两阶段优化调度框架。文献[16]面向风电系统提出了一种MPC框架下的有功/无功协调控制方法,成功降低了风电场的能量损耗及风机传动链的疲劳负荷。文献[17]构建了基于模型预测控制的水电制氢系统多目标优化调度模型,在水电消纳能力不足时,实现了经济效益最大化与流域弃水量最小化的协同优化。文献[18]提出了基于随机模型预测控制 (Stochastic model predictive control, SMPC) 的多时间尺度最优调度模型,在跟踪可再生能源波动上表现优越,有效提升了系统运行经济性。上述研究结果表明模型预测控制策略在应用于不同系统架构下,均取得了显著的调度控制效果。

然而,针对离网型绿电制氢合成氨系统,现有研究在调控策略方面,对如何利用闭环控制机制应对可再生能源出力波动及其对系统稳定性的影响考虑较少。因此,本文提出一种基于风光功率预测与场景分析的随机模型预测控制调度策略,以实现可再生能源消纳率最大化与合成氨系统稳定运行的双重目标。研究内容与结构安排如下:首先,构建离网型绿电制氢合成氨系统的状态空间动态模型,表征关键设备的动态特性及其协同调控关系,并确立优化目标函数及系统运行约束条件。其次,提出风光出力预测模型与风光出力不确定性量化方法,并设计基于随机模型预测控制的优化调度策略。最后,基于实际风光出力数据进行算例仿真,对建立的模型及随机模型预测控制调度策略进行验证与评估。

1 绿电制氢合成氨系统模型

1.1 系统整体结构

绿电制氢合成氨系统的整体结构如图1所示。从图中可以看出, 该系统主要由可再生能源发电工段、电解制氢工段与储氢工段、合成氨工段构成。可再生能源发电工段分风力发电和光伏发电2部分, 功能是将风能和太阳能转化为电能。一方面, 电能可直接用于后续的电解水制氢环节, 合成氨环节; 另一方面, 部分电能可对蓄电池进行充电, 以储存多余电能, 确保系统在可再生能源发电量不足时仍能保持供电稳定。




图1 绿电制氢合成氨系统整体结构

Fig. 1 Structure of the off-grid green power-to-hydrogen-to-ammonia system

绿电制氢合成氨系统涉及的关键设备包括电解槽、压缩机、蓄电池、储氢罐以及合成氨塔。鉴于风光能源系统的动态波动特性, 构建关键设备协同调控的系统运行模型至关重要。

在可再生能源供给充裕的时段, 应充分发挥电解槽负荷响应快的优势, 通过其高负荷运行提升产氢速率, 同步实施多设备协同调控策略: 对合成氨装置进行产能爬坡控制, 逐步扩大产量; 动态提升压缩机的运行功率, 以满足合成氨塔的输入需求; 并将剩余电能输送至储能系统进行储存, 进一步提升能源利用效率与系统稳定性。

在可再生能源供给不足时段, 实时限制电解槽运行功率, 同时利用储氢罐的储备资源维持合成氨的连续生产, 并通过压缩机功率降载与合成氨装置动态调节实现产能柔性收缩。用该协同控制策略能够有效保障电力供需波动下氨生产系统的稳定运行, 避免非计划停机。因此, 首先需要

对上述关键设备进行分析并建立模型。

1.2 电解制氢、合成氨工段模型

电解槽是实现可再生能源电能向化学能（氢气）高效转换的核心设备, 其快速响应特性可有效应对能源波动性。在电解水制氢过程中, 碱性电解槽的能量转换效率基本恒定, 因此采用线性模型描述输入电能与输出制氢流量的关系^[19]:

$$P_{\text{ele}} = \eta_{\text{ele}} Q_{\text{H}_2} \quad (1)$$

式中: P_{ele} 为电解槽输入的电功率; η_{ele} 为电解水制氢的效率; Q_{H_2} 为氢气流量。

合成氨塔是绿电制氢合成氨系统中实现氨合成反应的关键设备, 其在催化剂作用下实现了将特定比例的氢气与氮气转化为氨气。该设备消耗的能量与氨产量之间的关系采用^[20]:

$$P_{\text{amm}} = \eta_{\text{amm}} Q_{\text{NH}_3} \quad (2)$$

式中: P_{amm} 为合成氨塔输入的电功率; η_{amm} 为合成氨塔制氨的效率; Q_{NH_3} 为氨产量。

1.3 储氢工段、蓄电池建模

储氢工段作用是通过储存富余电力生产的氢气, 有效应对风光发电的间歇性和波动性。储氢罐的氢气存储量由电解制氢量与合成氨耗氢量的差值决定。据此可建立储氢罐压力水平与电解槽、合成氨塔功率的状态空间离散表达式:

$$S_{\text{OHC}}(k+1) = S_{\text{OHC}}(k) + \frac{T}{\eta_{\text{ele}} V_{\text{max}}} P_{\text{ele}}(k) - \frac{\alpha T}{\eta_{\text{amm}} V_{\text{max}}} P_{\text{amm}}(k) \quad (3)$$

式中: k 为当前时刻; $(k+1)$ 为下一时刻; S_{OHC} 表示储氢罐压力水平; T 为采样时间; η_{ele} 为电解制氢效率; η_{amm} 为合成氨效率; α 为比例系数; P_{ele} 和 P_{amm} 分别为电解槽和合成氨塔功率; V_{max} 为储氢罐的最大储氢容量。

蓄电池的荷电状态 (State of charge, SOC) 由其充放电情况决定, 其状态空间离散表达式采用^[21]:

$$S_{\text{OC}}(k+1) = S_{\text{OC}}(k) - \frac{\alpha_{\text{bat}} T}{C_{\text{max}}} P_{\text{bat}}(k) \quad (4)$$

式中: α_{bat} 为蓄电池的工作效率; P_{bat} 为蓄电池的充放电功率, 当 $P_{\text{bat}} > 0$ 时蓄电池放电, 当 $P_{\text{bat}} < 0$ 时蓄电池则充电; C_{max} 为蓄电池的最大容量。

1.4 系统整体模型状态空间表达式

综上, 构建系统整体状态空间表达式。

绿电制氢合成氨系统的功率平衡方程为:

$$P_{\text{wind}} + P_{\text{solar}} = P_{\text{ele}} + P_{\text{amm}} - P_{\text{bat}} + P_{\text{c}} \quad (5)$$

式中: P_{wind} 、 P_{solar} 分别为风电、光伏发电功率。

可控设备消耗的功率为电解槽、蓄电池、压缩机、合成氨塔的功率, 其方程为:

$$P_{\text{load}} = P_{\text{ele}} + P_{\text{amm}} - P_{\text{bat}} + P_{\text{c}} \quad (6)$$

式中: P_{load} 为可控设备消耗的功率总和; P_{c} 为压缩机功率。

通过上述分析, 可得到绿电制氢合成氨系统的线性离散状态空间表达式为:

$$\begin{cases} \mathbf{x}(k+1) = \mathbf{A}\mathbf{x}(k) + \mathbf{B}\mathbf{u}(k) \\ \mathbf{x} = [S_{\text{OHC}} \quad S_{\text{OC}} \quad P_{\text{load}}]^T \\ \mathbf{u} = [P_{\text{ele}} \quad P_{\text{amm}} \quad P_{\text{bat}} \quad P_{\text{c}}]^T \end{cases} \quad (7)$$

$$\mathbf{A} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

$$\mathbf{B} = \begin{bmatrix} \frac{T}{\eta_{\text{ele}} V_{\text{max}}} & -\frac{\alpha T}{\eta_{\text{amm}} V_{\text{max}}} & 0 & 0 \\ 0 & 0 & -\frac{\alpha_{\text{bat}} T}{C_{\text{max}}} & 0 \\ 1 & 1 & -1 & 1 \end{bmatrix} \quad (8)$$

式中: $\mathbf{x}$ 为状态变量; $\mathbf{u}$ 为控制变量; $\mathbf{A}$ 和 $\mathbf{B}$ 分别为状态变量矩阵和控制变量矩阵。

在建立绿电制氢合成氨系统状态空间模型后, 需明确系统调度的目标函数、状态变量和控制变量的约束条件, 以实现系统的有效调度控制。

1.5 系统目标函数及约束条件

系统的调控目标主要包含两方面: 一是最大化消纳风光能源以避免浪费; 二是在保障合成氨装置 (因其具有较大惯性) 稳定运行的前提下, 最大化其合成氨产量。绿电制氢合成氨系统在每个仿真时间步 k 时刻求解的目标函数为:

$$\min \sum_{M=1}^j \pi_j \left\{ \sum_{N=1}^i W [P_{\text{load}}(k+i|k) - P_{\text{wind}}(k+i|k) - P_{\text{solar}}(k+i|k)]^2 + \sum_{N=1}^l Q \Delta u^2(k+l-1|k) \right\} \quad (9)$$

式中: M 为场景的数量; π_j 为第 j 个经典场景发生的概率; N 为模型预测控制的预测时域; Δu 为

<http://dlkxygc.ncepu.edu.cn>

控制变量增量; W 和 Q 为权重系数, 其取值为:

$$W=6, \quad \mathbf{Q} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 4 & 0 & 0 \\ 0 & 0 & 5 & 0 \\ 0 & 0 & 0 & 3 \end{bmatrix}.$$

1.6 系统约束条件

绿电制氢合成氨系统的目标函数求解需满足多项约束条件, 以确保在寻优时系统能够稳定运行。各典型场景下每个仿真步的约束条件如下。

系统状态变量等式约束为:

$$\mathbf{x}(k+1) = \mathbf{A}\mathbf{x}(k) + \mathbf{B}\mathbf{u}(k) \quad (10)$$

系统功率平衡约束为:

$$P_{\text{wind}}(k) + P_{\text{solar}}(k) = P_{\text{ele}}(k) + P_{\text{amm}}(k) - P_{\text{bat}}(k) + P_{\text{c}}(k) \quad (11)$$

各设备出力的上下限约束为:

$$\begin{cases} P_{\text{ele}}^{\min} \leq P_{\text{ele}}(k) \leq P_{\text{ele}}^{\max} \\ P_{\text{amm}}^{\min} \leq P_{\text{amm}}(k) \leq P_{\text{amm}}^{\max} \\ P_{\text{bat}}^{\min} \leq P_{\text{bat}}(k) \leq P_{\text{bat}}^{\max} \\ P_{\text{c}}^{\min} \leq P_{\text{c}}(k) \leq P_{\text{c}}^{\max} \end{cases} \quad (12)$$

储氢罐及蓄电池储量约束为:

$$\begin{cases} S_{\text{OCmin}} \leq S_{\text{OC}}(k) \leq S_{\text{OCmax}} \\ S_{\text{OHCmin}} \leq S_{\text{OHC}}(k) \leq S_{\text{OHCmax}} \end{cases} \quad (13)$$

各设备的功率变化速率约束为:

$$\begin{cases} \Delta P_{\text{ele}}^{\min} \leq P_{\text{ele}}(k+1) - P_{\text{ele}}(k) \leq \Delta P_{\text{ele}}^{\max} \\ \Delta P_{\text{amm}}^{\min} \leq P_{\text{amm}}(k+1) - P_{\text{amm}}(k) \leq \Delta P_{\text{amm}}^{\max} \\ \Delta P_{\text{bat}}^{\min} \leq P_{\text{bat}}(k+1) - P_{\text{bat}}(k) \leq \Delta P_{\text{bat}}^{\max} \\ \Delta P_{\text{c}}^{\min} \leq P_{\text{c}}(k+1) - P_{\text{c}}(k) \leq \Delta P_{\text{c}}^{\max} \end{cases} \quad (14)$$

在建立绿电制氢合成氨系统状态空间模型、明确优化目标函数及系统约束条件后, 采用随机模型预测控制策略进行调度控制, 通过在每个时间步求解系统最优状态, 得到整个时间范围内的最佳调度结果。

2 基于随机模型预测控制优化调度

在绿电制氢合成氨系统中, 风光出力的间歇性与波动性会导致系统运行不稳定, 因此精准捕捉风光功率的变化是优化调度的基础。通过融合 Transformer 架构的时序特征提取能力与知识激活网络 (Knowledge activation network, KAN) 的非线性映射优势, 本文构建 Transformer-KAN 混合预测模型, 实现风光出力的高精度预测, 为后续

调度策略提供可靠的出力预测数据。

然而, 由于风光可再生能源固有的强不确定性, 单一预测值难以充分表征其潜在波动范围。因此, 基于风光预测数据, 采用拉丁超立方抽样技术生成大规模初始场景集以量化风光出力不确定性。为减少大规模场景集带来的计算负荷, 引入 *K*-means 聚类技术进行场景削减, 在保留关键特征和波动模式的前提下, 得到典型场景集, 有效平衡表征精度与计算效率。随后将削减后的典型场景集输入到随机模型预测控制框架中, 通过滚动优化与反馈校正求解各时刻系统调度最优解, 从而获得整个时间范围上的最优调度结果。

2.1 Transformer-KAN 预测模型

针对风光出力的强随机性与时空耦合特性, 本研究提出的 Transformer-KAN 混合预测框架, 其结构如图 2 所示。从图中可以看出, 该框架将 Transformer 前馈神经网络替换为 KAN 网络, 通过可学习激活函数规避维数灾难, 同时提升模型可解释性。相较传统模型, Transformer-KAN 能够以更灵活的方式捕捉输入数据间复杂的非线性关系, 从而在预测精度与泛化能力上实现双重提升。




图 2 Transformer-KAN 结构
Fig. 2 Transformer-KAN structure

如图 2 所示, Transformer-KAN 模型采用编码器-解码器架构。输入数据经词嵌入和位置编码融

合后, 进入多层编码器: 每层利用多头自注意力捕捉全局依赖, 并以 KAN 网络替代前馈神经网络进行深度非线性特征提取, 辅以残差连接和层归一化优化训练。解码器同样多层堆叠, 首先通过掩码多头自注意力确保输出时序正确性, 再经编码器-解码器注意力关联编码特征; 同样以 KAN 替代前馈神经网络进行特征变换, 结合残差与层归一化精准构建目标表示。最终输出经线性层和 Softmax 生成预测结果, 为后续场景生成与缩减提供数据来源。

2.2 场景生成与缩减

针对 Transformer-KAN 预测所得风光功率数据, 构建“场景生成-削减”处理机制。在场景生成阶段, 采用拉丁超立方抽样方法生成大规模风光发电场景集。该方法通过分层采样策略, 确保样本在变量空间内均匀分布, 能够全面且精准地刻画风光出力的随机特性。然而, 随着场景数量的增长, 计算复杂度的大幅提升会导致求解过程的计算量剧增。

为综合考虑计算精度和计算负担, 采用基于 *K*-means 聚类的场景削减方法进行场景削减。该方法以 *K*-means 算法为基础, 依据类内距离最小化原则, 通过迭代优化的方式, 将拉丁超立方抽样生成的大量场景集整合为具有代表性的典型场景集。 *K*-means 聚类场景缩减流程如图 3 所示。




图 3 *K*-means 聚类的场景削减流程
Fig. 3 *K*-means clustering based scenario reduction flowchart

该方法在保证预测精度的同时显著提升了系统优化调度的计算可行性,为绿电制氢合成氨系统的实时调度提供了高效解决方案。

2.3 模型预测控制

为应对风光出力的不确定性,在构建具有代表性且包含概率特征的典型场景集基础上,本文引入模型预测控制(MPC)策略,对绿电制氢合成氨系统的动态运行过程进行优化调度。该方法融合滚动优化与反馈校正两大机制,构建双层闭环控制结构,在系统运行过程中增强对外部扰动与模型偏差的鲁棒性。

2.3.1 滚动优化

在 MPC 框架中,将已获得的风光出力典型场景集作为不确定性输入参数输入到控制模型中。在每一个控制步长 k 时刻,系统通过求解带约束的优化目标函数,生成在预测时域 N 内的最优控制序列, $\{u(k|k), \dots, u(k+j-1|k), \dots, u(k+N-1|k)\}$ 。其中 $u(k+j-1|k)$ 表示以 k 时刻系统状态预测的未来 $(k+j-1)$ 时刻控制指令。

在实施过程中,首先要将优化序列的首项 $u(k|k)$ 作用于系统。随后,将系统在下一时刻 $(k+1)$ 的实际响应状态作为新的初始状态,重复执行上述优化过程。这种滚动时域优化策略,将传统开环的离线全局优化方法转变为有限时域内的在线滚动优化,显著降低了模型失配与外部干扰对系统性能的不利影响,增强了对风光出力波动的自适应调节能力,从而有效提升了绿电制氢合成氨系统的动态鲁棒性与运行可靠性。

2.3.2 反馈校正

鉴于风光出力的不确定性会导致模型预测误差随时间累积,单纯依赖预测信息可能使系统性能逐步下降。为此,引入反馈校正机制,对控制系统的动态偏差进行实时修正,从而提升系统对风光出力不确定性的鲁棒性。具体实施过程中,在每个仿真步 $(k+1)$ 时刻,将 k 时刻计算得到的最优控制序列首项作用于系统。

反馈机制确保了控制系统能够持续响应外部扰动与预测误差的变化,从而增强了对风光出力随机性的适应能力。通过滚动优化与反馈校正的协同作用, MPC 策略有效提升了系统控制的精度与稳定性,为绿电制氢合成氨系统实现高效、安全运行提供了可靠保障。

<http://dlkxygc.ncepu.edu.cn>

2.4 整体流程

绿电制氢合成氨系统整体调度流程如图 4 所示。从图中可以看出,系统首先利用 Transformer-KAN 混合预测模型对风光发电功率进行时序建模,获得风光出力预测数据。然后,采用拉丁超立方抽样方法生成初始场景样本集。考虑到大规模场景集带来的计算复杂度激增问题,引入基于 K-means 聚类的场景削减技术,保留最具有代表性的典型场景,最终形成能够精确表征风光出力不确定性的精简场景集。




图 4 绿电制氢合成氨系统调度流程

Fig. 4 Scheduling of green power-to-hydrogen-to-ammonia system

将上述典型场景集输入模型预测控制框架后,对状态变量参数进行初始化,求解当前时刻的最优控制序列,并将改序列的第一项作用于系统,得到最新的状态变量值,将改状态变量值作为下一时刻的初始状态变量值,继续求解下一时刻的最优控制序列。依图 4 重复此过程,最终得到整个时间段上的调度结果。

3 算例仿真

3.1 仿真环境与参数配置

将随机模型预测控制策略应用于绿电制氢合成氨系统的仿真配置。在仿真实验中, 为充分覆盖可再生能源出力的日内波动特性, 选取某风光电站连续 24 h 的运行场景开展仿真分析, 时间分辨率为 15 min, 总计 96 个采样时刻。优化问题的求解使用 MATLAB 内置的 fmincon 求解器, 并采用内点法求解。电氢氨系统仿真的具体参数配置详见附录 A 中表 A1。

3.2 风光能源场景生成与削减结果分析

在风光出力场景生成与削减实验中, 为充分表征其随机特性, 初始场景集规模设定为 1 000 个样本。鉴于大规模场景集带来的计算负荷, 采用基于 *K*-means 聚类的场景削减技术, 将场景数量削减至 5 个最具代表性的典型场景, 有效平衡计算效率与表征精度。

以某日风电出力为例, 图 5 展示了基于拉丁超立方抽样技术生成的 1 000 个初始场景集; 图 6 为经 *K*-means 聚类削减后得到的 5 个典型场景。由图 5 可以看出, 拉丁超立方抽样产生的初始场景能够均匀分布于风电出力可能波动的整个区间, 有效刻画了其不确定性。由图 6 可知, 通过 *K*-means 聚类削减, 在显著降低场景集规模的同时, 保留了具备关键特征及高度代表性的聚类中心场景, 从而在减轻计算负荷的同时, 确保了风电出力典型波动性的准确表征。




图 5 风出力初始场景集

Fig. 5 Initial scenarios of wind output




图 6 风出力典型场景集

Fig. 6 Typical scenarios of wind output

3.3 SMPC 调度结果分析

基于 SMPC 策略的绿电制氢合成氨系统调度控制结果如图 7 所示。通过分析图 7 可知:




图 7 系统调度优化结果

Fig. 7 System scheduling optimization results

时序 0—14, 风光出力处于峰值区域, 为最大化可再生能源的利用率, 电解槽、压缩机及合成

氨塔均以高负荷运行。蓄电池充电, 其荷电状态相应提升。同时, 电解槽的高负荷运行促使储氢

罐氢气存量有所上升。

时序 14—40, 风光出力整体下降, 系统进入低出力阶段, 各设备功率同步下调, 储能系统 SOC 与 SOHC 呈缓降趋势。值得注意的是, 在 25—30 时序的可再生能源短时间波动期间, 电解槽凭借其快速响应特性, 有效平抑功率波动。

时序 40—96, 可再生能源出力再度升高, 系

统各设备呈现协同响应。电解槽迅速提升负荷, 消纳 85% 以上功率波动; 压缩机、合成氨塔装置逐步提升负荷; 同时过剩电能则被储存至蓄电池, 蓄电池 SOC 与储氢罐 SOHC 显著上升。

3.4 随机模型预测控制 (SMPC) 策略验证

为验证 SMPC 策略的有效性, 选择使用 MPC 策略进行对比实验, 实验结果如图 8 所示。




图 8 SMPC、MPC 两种策略下系统调度优化结果对比

Fig. 8 Comparison of system scheduling optimization results under SMPC and MPC strategies

从图 8 可以看出, 各设备出力、储氢罐 SOHC 及蓄电池 SOC 在两种策略下的变化趋势基本保持一致。然而, SMPC 策略凭借多场景不确定性量化机制, 呈现出更优的系统适应性, 使设备总出力对风光出力的跟踪更为精准, 波动响应过程更平滑。在风光出力高峰时段 (时序 0—14), SMPC 策略通过多场景概率加权的优化目标函数, 其风光消纳率显著优于 MPC 策略。在风光出力波动期间 (时序 55—70), SMPC 策略下电解槽、合成氨塔和蓄电池设备的出力更加平稳, 相比 MPC 策略能更有效地应对风光波动, 提升了系统运行的平稳性和可靠性。相比之下, MPC 策略因未考虑风光出力的多场景不确定性, 导致设备出力与风光实际波动存在偏差, 尤其在出力剧烈波动时段,

跟踪效果略显不佳。

以上分析表明, 随机模型预测控制策略在绿电制氢合成氨系统中展现出优异的调控性能。电解槽凭借其快速响应特性, 成为消纳风光出力的核心设备, 压缩机、合成氨塔及蓄电池则基于各自动态特性与电解槽协同运行, 共同实现对风光能源的最大化消纳, 保障合成氨过程的稳定。

实验具体数据结果表明, 优化后的 SMPC 策略在绿电制氢合成氨系统中展现出较好性能: 其风光消纳率高达 99.86%, 相较 MPC 策略的 98.23%, 其消纳能力优势明显。同时, SMPC 策略下合成氨塔的平均功率达到 4.99 MW, 相比 MPC 策略的 4.96 MW 有所提升, 功率输出稳定性与效率均实现优化。

4 结论

本文针对绿电制氢合成氨系统中可再生能源波动性对系统稳定运行造成的影响, 提出了一种基于风光功率预测的电氢氨系统优化调度策略。通过实验分析, 可得到以下主要结论:

1) 采用基于 Transformer-KAN 模型与场景分析方法构建的风光出力预测体系, 能够有效反映可再生能源的时序变化与不确定性特征。在此基础上, 采用拉丁超立方抽样与 K -means 聚类方法生成的典型场景集, 可为调度提供了准确可靠的输入数据。

2) 采用随机模型预测控制策略对绿电制氢合成氨系统进行动态优化调度, 通过滚动优化与反馈校正机制协同作用, 充分发挥了各设备的运行特性, 在保障合成氨装置稳定运行的基础上, 有效消纳了风光能源, 提高了能源利用率。

参考文献:

- [1] 王杰, 逯雅梅. “双碳”目标下氢能的发展现状与应用前景[J]. 现代化工, 2025, 45(S1): 22-23.
- [2] 赵腾飞, 刘庆, 陈英杰, 等. 可再生能源发电制绿氢的发展趋势及前景展望[J]. 太阳能学报, 2025, 46(4): 39-48.
- [3] 杜逸云, 刘路尧, 陈越, 等. 耦合不同制氢技术的合成氨系统技术经济性分析及碳排放评估[J]. 热力发电, 2025, 54(5): 1-12.
- [4] SALMON N, BAÑARES-ALCÁNTARA R. Green ammonia as a spatial energy vector: a review[J]. Sustainable Energy & Fuels, 2021, 5(11): 2814-2839.
- [5] MÜLLER M, PFEIFER M, HOLTZ D, et al. Comparison of green ammonia and green hydrogen pathways in terms of energy efficiency[J]. Fuel, 2024, 357: 129843.
- [6] ASIF M, BIBI S S, AHMED S, et al. Recent advances in green hydrogen production, storage and commercial-scale use via catalytic ammonia cracking[J]. Chemical Engineering Journal, 2023, 473: 145381.
- [7] 李晓宇, 吴果莲, 苑秀娥, 等. 可再生能源发电侧储能项目经济评价研究[J]. 电力科学与工程, 2023, 39(8): 41-52.
- [8] 周步祥, 朱文聪, 朱杰, 等. 风光制氢合成氨系统的多时段可调度域分析[J]. 中国电机工程学报, 2024, 44(1): 160-174.
- [9] 林今, 余志鹏, 张信真, 等. 可再生能源电制氢合成氨系统的并/离网运行方式与经济性分析[J]. 中国电机工程学报, 2024, 44(1): 117-127.
- [10] 郑勇, 邓欣, 吉旭, 等. 适应风光波动的绿氨多稳态柔性调度方法[J]. 洁净煤技术, 2025, 31(3): 128-137.
- [11] 马翱凯, 宁超. 面向绿电-氢-氨耦合系统的自适应分布鲁棒调度优化[J]. 洁净煤技术, 2025, 31(3): 120-127.
- [12] WU Y, ZHAO T T, TANG S, et al. Research on design and multi-frequency scheduling optimization method for flexible green ammonia system[J]. Energy Conversion and Management, 2024, 300: 117976.
- [13] ABDELGHANY M B, MARIANI V, LIUZZA D, et al. Hierarchical model predictive control for islanded and grid-connected microgrids with wind generation and hydrogen energy storage systems[J]. International Journal of Hydrogen Energy, 2024, 51: 595-610.
- [14] SÁNCHEZ A, CASTELLANO E, MARTÍN M, et al. Evaluating ammonia as green fuel for power generation: a thermo-chemical perspective[J]. Applied Energy, 2021, 293: 116956.
- [15] 林永君, 孟耀兵, 张聪聪, 等. 基于模型预测控制的多微网系统 2 阶段优化调度[J]. 电力科学与工程, 2023, 39(4): 28-40.
- [16] 杨彦霞, 李少林, 王伟胜, 等. 考虑运行经济性与安全性的风电场功率模型预测优化控制[J]. 太阳能学报, 2024, 45(10): 521-528.
- [17] 郑之杰, 黄静思, 黄元生. 基于模型预测控制的水电制氢系统优化调度研究[J]. 电力科学与工程, 2022, 38(7): 25-33.
- [18] WANG K, WANG C F, ZHANG Z W, et al. Multi-timescale active distribution network optimal dispatching based on SMPC[J]. IEEE Transactions on Industry Applications, 2022, 58(2): 1644-1653.
- [19] LI J, LIN J, HEUSER P M, et al. Co-planning of regional wind resources-based ammonia industry and the electric network: a case study of inner Mongolia[J]. IEEE Transactions on Power Systems, 2021, 37(1): 1-12.

65-80.

[20] KLYAPOVSKIY S, ZHENG Y, YOU S, et al. Optimal operation of the hydrogen-based energy management system with P2X demand response and ammonia plant[J]. Applied Energy, 2021, 304: 117559.

[21] 刘亚伟, 关朋, 孙陆楠, 等. 基于峰谷电价与储能 SOC 状态的微电网能量调度策略研究[J]. 电气传动, 2024, 54(12): 71-78.

收稿日期: 2025-06-18

作者简介:

王东风 (1971—), 男, 教授, 研究方向为先进控制理论及应用、智能发电系统分析与优化、智能检测与软测量技术;

师鑫鑫 (2001—), 男, 硕士研究生, 研究方向为综合能源系统优化调度;

崔玉雷 (2000—), 男, 硕士研究生, 研究方向为先进控制理论研究与应用;

梁博彦 (2002—), 男, 硕士研究生, 研究方向为综合能源系统建模与优化;

黄宇 (1982—), 男, 副教授, 研究方向为综合能源系统建模与优化、先进控制理论研究与应用等。

通信作者: 黄宇

附录 A:

表 A1 电氢氨系统仿真参数

Tab. A1 Simulation parameters of an electro-hydrogen-ammonia system

变量	单位	数值
S_{OC}^{init}	—	0.2
S_{OHC}^{init}	—	0.4
P_{load}^{init}	MW	0
$S_{OC}^{min} \sim S_{OC}^{max}$	—	0.1~0.9
$S_{OHC}^{min} \sim S_{OHC}^{max}$	—	0.1~0.9
$P_{ele}^{min} \sim P_{ele}^{max}$	MW	1~50
$P_{amm}^{min} \sim P_{amm}^{max}$	MW	2~15
$P_{bat}^{min} \sim P_{bat}^{max}$	MW	-10~10
$P_c^{min} \sim P_c^{max}$	MW	2~20
$\Delta P_{ele}^{min} \sim \Delta P_{ele}^{max}$	MW	-6~6
$\Delta P_{amm}^{min} \sim \Delta P_{amm}^{max}$	MW	-2~2
$\Delta P_{bat}^{min} \sim \Delta P_{bat}^{max}$	MW	-3~3
$\Delta P_c^{min} \sim \Delta P_c^{max}$	MW	-5~5

表 A1 中, S_{OC}^{init} 、 S_{OHC}^{init} 和 P_{load}^{init} 分别为系统初始时刻参数设定值; $P^{min} \sim P^{max}$ 为设备运行功率上下限约束; $\Delta P^{min} \sim \Delta P^{max}$ 为设备爬坡约束。